

NIPT 检测时点的优化选择与胎儿染色体异常的判定

摘要：无创产前检测（NIPT）通过分析母体血液中胎儿游离 DNA 判断染色体异常，其准确性由胎儿染色体浓度决定。本文基于附件中 267 位孕妇的 1082 条男胎检测记录、147 位孕妇的 605 条女胎检测记录，围绕 Y 染色体浓度的达标时点选择与女胎异常判定建立统计模型。**问题一**，对 1082 条男胎记录进行相关性分析与混合效应建模，发现 Y 染色体浓度与孕周正相关（偏相关系数 0.153）、与 BMI 负相关（偏相关系数 -0.174 ），二者均高度显著；考虑到数据为纵向追踪结构（1082 条记录来自 267 位孕妇），采用随机截距混合效应模型，得到孕周与 BMI 对浓度的固定效应分别为 0.044 周^{-1} 与 -0.021 ，个体间差异解释了总变异的 72.6%。**问题二**，以 σ_u 与 σ_{total} 区分真实达标与含测量误差的测得达标，将最佳检测时点定义为达标比例达到 80% 的最早孕周，按临床肥胖分级将 BMI 分为四组，解得各组最佳时点为 10.0、11.9、13.8、15.7 周，且检测误差使达标时间平均推迟 2.06 周。**问题三**，在达标模型中引入年龄与身高多因素，经 AIC 准则筛选得最优模型，各组最佳时点修正为 10.6、11.6、13.2、15.9 周，并量化了测量误差的敏感性。**问题四**，以 21/18/13 号染色体非整倍体为标签建立女胎异常分类模型，发现传统 $|Z| > 3$ 阈值法敏感度仅 6%，而综合 X 染色体浓度、GC 含量等多特征的逻辑回归模型 AUC 达 0.794，其中 X 染色体浓度是最重要特征，验证了临床“女胎以 X 染色体浓度判断检测可靠性”的经验。

关键词：无创产前检测；混合效应模型；达标时间；风险最小化；染色体非整倍体；分类

1 问题重述

无创产前检测（NIPT）通过采集母体血液、检测胎儿游离 DNA 片段分析染色体是否异常。畸形胎儿主要由 21 号、18 号、13 号染色体游离 DNA 片段比例（染色体浓度）异常所致。NIPT 的准确性由胎儿性染色体浓度判断：男胎 Y 染色体浓度达 4% 及以上、女胎 X 染色体浓度无异常时，检测结果基本准确。检测时点过早会导致浓度不足、结果不可靠；过晚则会缩短异常胎儿的治疗窗口期，12 周内发现风险较低，13–27 周风险较高，28 周后风险极高。胎儿的 Y 染色体浓度与孕妇孕周、BMI 等指标密切相关，需对孕妇合理分组并确定各组的最佳检测时点。

附件提供了某地区（多为高 BMI）孕妇的 NIPT 数据，含多次采血检测与测序失败情形。据此建立数学模型解决四个问题：分析 Y 染色体浓度与孕周、BMI 的相关性并建模检验显著性；对男胎孕妇 BMI 合理分组并给出最佳 NIPT 时点以最小化潜在风险；综合身高、体重、年龄、检测误差与达标比例改进分组与时点；综合 Z 值、GC 含量、读段数及比例、BMI 等因素给出女胎异常判定方法。

2 问题分析

四个问题构成递进链条：问题一的相关性模型为问题二、三的达标时间估计提供输入，问题二的风险定义沿用至问题三，问题四则从男胎的“浓度达标”转向女胎的“异常判定”。

问题一的关键在于识别数据的纵向结构。附件中 1082 条男胎记录来自 267 位孕妇，其中 260 位有多次采血，同一孕妇在不同孕周多次检测。若忽略个体重复测量，直接做横截面回归会因“孕周与 BMI 正相关”这一混杂而低估孕周效应，故须采用混合效应模型分离个体差异。

问题二的核心是“潜在风险”的量化。检测过早则浓度不足、结果不可靠；检测过晚则延误干预。最佳时点应在“达标概率”与“延误风险”之间权衡。达标时间定义为达标比例达到给定置信度的最早孕周，其中需区分真实达标（仅个体差异）与含测量误差的测得达标。

问题三在问题二基础上引入年龄、身高等多因素，并用 AIC 准则筛选变量以处理体重与 BMI 的共线性。

问题四是监督分类问题，以非整倍体为标签。观察发现异常样本的 Z 值并未显著偏离 3，说明传统阈值法失效，需综合多特征建模。

3 模型假设与符号说明

3.1 模型假设

- (1) 每次采血检测为独立测量，测量误差服从正态分布且无系统偏差。
- (2) 胎儿 Y 染色体浓度（取对数后）与孕周近似线性相关，在检测窗口 10–29 周内该线性关系成立。
- (3) 孕妇个体差异通过随机截距刻画，个体间相互独立。
- (4) 附件中的非整倍体标签（AB 列）为可供建模的判定结果。

3.2 符号说明

符号	含义
Y	胎儿 Y 染色体浓度（游离 DNA 片段比例）
t	检测孕周（周）
BMI	孕妇身体质量指数
$F(t)$	达标比例，即 $Y \geq 4\%$ 的比例
t^*	最佳 NIPT 检测时点
σ_u^2	孕妇个体间方差（随机截距）
σ_e^2	测量误差方差（残差）
σ_{total}^2	总方差， $\sigma_u^2 + \sigma_e^2$

4 问题一：Y 染色体浓度与孕周、BMI 的相关性模型

4.1 数据预处理

孕周原始记录为”周数 + 天数”格式（如”11w+6”），统一转换为连续数值 $t = 11 + 6/7 \approx 11.86$ 周。Y 染色体浓度 Y 呈右偏分布（范围 0.010 ~ 0.234），故对 Y 取自然对数 $\ln Y$ 以改善正态性与方差齐性。描述性统计见表 1。

表 1: 关键变量描述性统计

变量	样本量	均值	标准差	最小值	中位数	最大值
孕周 t （周）	1082	16.85	4.08	11.00	16.00	29.00
BMI	1082	32.29	2.97	20.70	31.81	46.88
Y 浓度 Y	1082	0.0772	0.0335	0.0100	0.0751	0.2342
年龄（岁）	1082	28.94	3.66	21.00	29.00	43.00

4.2 相关性分析

计算 Pearson 与 Spearman 相关系数矩阵，结果见表 2。Y 浓度与孕周呈弱正相关（ $r = 0.127$ ），与 BMI 呈弱负相关（ $r = -0.151$ ），方向均符合临床预期：孕周推进使胎儿 DNA 占比上升，高 BMI 因母体血容量增大而稀释胎儿 DNA。

表 2: Y 浓度与主要指标的相关系数

变量对	Pearson	Spearman	偏相关 (p 值)
Y 浓度 ~ 孕周	0.127	0.084	0.153 (4.5×10^{-7})
Y 浓度 ~ BMI	-0.151	-0.155	-0.174 (9.2×10^{-9})

由于孕周与 BMI 本身正相关 ($r = 0.150$)，二者存在混杂。计算偏相关系数：控制 BMI 后，Y 浓度与孕周的偏相关为 0.153 ($p = 4.5 \times 10^{-7}$)；控制孕周后，Y 浓度与 BMI 的偏相关为 -0.174 ($p = 9.2 \times 10^{-9}$)。偏相关均比简单相关更强，说明消除混杂后两个因素的真实效应更显著。图 1 与图 2 分别展示了 Y 浓度随孕周、随 BMI 的散点分布，图 3 为相关矩阵热力图。




图 1: Y 染色体浓度与孕周的散点分布 (颜色表示 BMI, 红虚线为 4% 达标阈值)




图 2: Y 染色体浓度与 BMI 的散点分布 (颜色表示孕周, 红虚线为 4% 达标阈值)




图 3: 主要指标的 Pearson 相关矩阵热力图

4.3 混合效应关系模型

数据为纵向追踪结构, 1082 条记录来自 267 位孕妇。若用普通最小二乘 (OLS) 回归, 重复测量不独立会导致标准误低估、系数偏倚。为此建立随机截距混合效应模型:

$$\ln Y_{ij} = \beta_0 + \beta_1(t_{ij} - \bar{t}) + \beta_2(\text{BMI}_{ij} - \overline{\text{BMI}}) + u_i + \varepsilon_{ij}, \quad (1)$$

其中 i 为孕妇、 j 为检测次数， $u_i \sim N(0, \sigma_u^2)$ 为个体随机效应， $\varepsilon_{ij} \sim N(0, \sigma_e^2)$ 为残差。自变量中心化以避免二次项与交互项共线。

模型估计结果见表 3。混合效应模型中孕周系数为 0.044 ($z = 18.7$, $p < 0.001$)，而横截面 OLS 的孕周系数仅 0.014 ($t = 4.1$)。二者差异源于混杂：高 BMI 孕妇倾向于更晚检测，横截面回归将“个体差异”误并入孕周效应。个体间方差占比 $ICC = \sigma_u^2 / (\sigma_u^2 + \sigma_e^2) = 72.6\%$ ，表明七成以上的变异来自孕妇个体差异，印证了采用混合效应模型的必要性。图 4 进一步展示了不同 BMI 组 Y 浓度随孕周的上升趋势，高 BMI 组的曲线整体更低，直观印证了 BMI 对浓度的负效应。

表 3: 混合效应模型估计结果（因变量 $\ln Y$ ）

项	估计值	标准误	z	p 值	95% 置信区间
截距 β_0	-2.653	0.026	-102.3	< 0.001	[-2.704, -2.602]
孕周 β_1	0.044	0.002	18.7	< 0.001	[0.039, 0.048]
BMI β_2	-0.021	0.007	-2.79	0.005	[-0.035, -0.006]
个体方差 σ_u^2	0.163	—	—	—	—
残差方差 σ_e^2	0.0615	—	—	—	—




图 4: 不同 BMI 组的 Y 浓度随孕周变化趋势（线性拟合，高 BMI 组整体更低）

4.4 显著性检验

对固定效应逐项做 t 检验：孕周与 BMI 的系数 p 值均小于 0.01，整体模型高度显著。嵌套模型 F 检验显示，加入 BMI 后模型显著优于仅含孕周的模型（ $F = 24.76$, $p < 0.001$ ）。残差诊断（图 5）表明残差近似正态、无显著异方差，模型设定合理。




图 5：问题一混合效应模型的残差诊断（残差-拟合图、QQ 图、直方图）

进一步检验非线性效应。在混合效应框架下加入孕周与 BMI 的二次项，结果见表 4。孕周二次项高度显著（ $p < 0.001$ ，似然比检验 $\chi^2 = 22.46$ ），BMI 二次项不显著（ $p = 0.398$ ）。孕周二次项系数为正（ $\hat{\beta}_3 = 0.00247$ ），反映 Y 浓度在孕周后段（18 ~ 29 周）增长加速的生理规律。然而将二次模型用于达标时间外推时，在决策窗口（10 ~ 16 周）内会产生无意义的预测（如 G4 组外推达标时间为 1.7 周），原因是孕周 10 ~ 14 周段样本稀疏、二次项在该段外推不可靠。故问题二、三仍采用线性模型，作为决策窗口内的稳健近似，与模型假设“对数浓度在检测窗口内线性相关”一致。

表 4：混合效应模型的二次项检验（ML 估计）

模型	AIC	新增二次项 p 值
M0: week+BMI	710.0	—
M1: + 孕周 ²	690.2	< 0.001
M2: +BMI ²	711.4	0.398

5 问题二：BMI 分组与最佳 NIPT 时点

5.1 潜在风险的量化

检测时点 t 的潜在风险由两部分构成：检测过早导致的浓度不达标风险 $1 - F(t)$ ，以及检测过晚导致的延误风险 $D(t)$ 。综合风险定义为

$$R(t) = (1 - F(t)) + \rho D(t), \quad (2)$$

其中 $F(t)$ 为达标比例 ($Y \geq 4\%$ 的比例), $D(t)$ 为题设的三级延误风险 ($t \leq 12$ 为低风险取 0, $13 \leq t \leq 27$ 为高风险取 1, $t \geq 28$ 为极高风险取 3), ρ 为延误相对检测不准的权重。延误权重 ρ 与置信水平 α 存在单调对应关系: α 越高、时点越晚, 等价于 ρ 越小。由于 α 具有明确的统计含义且便于标定, 本文直接以 α 作为风险权衡参数, 而不凭经验设定 ρ 。

达标比例 $F(t)$ 由混合效应模型预测分布给出。对给定 BMI 与孕周, $\ln Y$ 服从 $N(\mu(t), \sigma^2)$, 其中 $\mu(t) = \beta_0 + \beta_1(t - \bar{t}) + \beta_2(\text{BMI} - \overline{\text{BMI}})$ 为固定效应预测。这里须区分两种方差: 以个体间方差 σ_u 刻画”真实达标比例”(生物学上的群体比例), 以总方差 $\sigma_{\text{total}} = \sqrt{\sigma_u^2 + \sigma_e^2}$ 刻画”测得达标比例”(含测量误差后实际可观测的比例)。二者的差异即量化了检测误差的影响。

5.2 BMI 分组

依据中国成人肥胖临床分级并兼顾样本量, 将 BMI 分为四组, 见表 5。组 G1 样本量仅 19 例, 但其达标时间由全部 1082 条记录估计的全局固定效应给出, 不依赖组内拟合, 故不受小样本影响。

表 5: BMI 分组及样本量


分组	BMI 区间	样本量	BMI 范围
G1	< 28	19	[20.7, 28.0]
G2	$28 \sim 32$	539	[28.0, 32.0]
G3	$32 \sim 36$	413	[32.0, 36.0]
G4	≥ 36	111	[36.1, 46.9]

5.3 最佳时点的确定

达标时间 t^* 满足 $\mu(t^*) - z_\alpha \sigma = \ln 0.04$, 即达标比例达到置信水平 α 的最早孕周。置信水平的选择需权衡: 95% 过于保守导致时点过晚 (18 ~ 25 周), 50% 过于宽松导致时点过早 (不足 10 周)。本文取 80% 作为最佳时点的判定标准, 理由有三: 其一, 经济与临床意义上, 80% 达标意味着每 5 人中 4 人一次检测即可达标, 其余复测, 这一比例在临床可接受; 其二, 统计上 80% 处于”过保守”与”过宽松”之间; 其三, 80% 给出的时点 10 ~ 16 周与 NIPT 临床常规检测窗口 (12–16 周) 吻合。为进一步量化该选择, 对 α 在 60% ~ 95% 间扫描, 结果见表 6 与图 6。

表 6: 不同置信水平 α 下的各组最佳时点（单位：周）

置信水平 α	G1	G2	G3	G4
60%	3.6	5.5	7.4	9.3
70%	6.6	8.5	10.4	12.3
80%	10.0	11.9	13.8	15.7
90%	14.8	16.7	18.6	20.5
95%	18.8	20.7	22.6	24.5

图 6: 最佳时点随置信水平 α 的变化 (80% 为本文取值)

由表 6 可见, $\alpha = 70\%$ 时 G1 组时点仅 6.6 周、早于 NIPT 临床可行窗口 (10 周); $\alpha = 85\%$ 及以上时 G2-G4 组均已进入 13 ~ 27 周的高风险区间。唯有 $\alpha = 80\%$ 使 G1、G2 组落在低风险区 (≤ 12 周)、G3、G4 组处于可接受区间, 且各组时点均不早于 10 周, 兼顾检测可靠性与干预及时性, 从数值上印证了 80% 阈值的选择。

各组最佳时点见表 7 与图 9。可见最佳时点随 BMI 单调后移: 低 BMI 组 10.0 周即可可靠检测, 而高 BMI 组需等到 15.7 周, 此时已进入 13-27 周的高风险区间, 说明高 BMI 孕妇面临更大的延误风险。

值得说明的是, 本文所得最佳时点 (10.0 ~ 15.7 周) 明显早于基于生存分析的 Kaplan-Meier 方法 (约 17 ~ 18 周)。二者差异源于对“达标”的定义不同: 生存分析以“个体首次测得 $Y \geq 4\%$ ”作为事件时间, 其达标中位时间天然偏晚, 反映的是最后一

批个体达标的时间；本文则以”群体达标比例达 80%”为标准，刻画的是绝大多数孕妇已能可靠检测的时点。从临床常规看，NIPT 多在 12 ~ 16 周实施，本文结果与之吻合；若将时点推迟至 17 ~ 18 周，反而过度保守、缩短异常胎儿的干预窗口。此外，生存分析中时间惩罚函数的参数（如指数速率与风险权重）通常凭经验设定，对最优时点影响较大且缺乏论证；本文的 80% 阈值则经经济、统计与临床三方面论证，稳健性更强。

表 7：各 BMI 组达标时间与最佳时点（单位：周）

分组	测得 80%	测得 90%	真实 90%	最佳时点	风险等级
G1 (BMI< 28)	10.0	14.8	12.8	10.0	低
G2 (28 ~ 32)	11.9	16.7	14.7	11.9	低
G3 (32 ~ 36)	13.8	18.6	16.6	13.8	高
G4 (BMI≥ 36)	15.7	20.5	18.4	15.7	高

图 7 展示了各组达标比例曲线与最佳时点，图 8 展示了达标时间随 BMI 的变化。




图 7：各 BMI 组测得达标比例随孕周变化（虚线为最佳时点）




图 8: 达标时间随 BMI 的变化 (真实达标与含误差的测得达标)




图 9: 各 BMI 组最佳 NIPT 时点 (背景色表示风险等级)

5.4 检测误差的影响

以 90% 置信为例，测得达标时间与真实达标时间的差即为测量误差 σ_e 导致的达标时间推迟。由表 7，各组的测得 90% 与真实 90% 之差均为 2.06 周，即检测误差平均使

达标时间推迟 2.06 周。进一步的聚类 bootstrap（对孕妇有放回抽样 200 次，保持同一孕妇的记录成组）给出最佳时点的分布，见表 8。各组时点的不确定性约 ± 1 周，且组间差异显著，结论稳健，各组最佳时点的 bootstrap 分布见图 10。

表 8: 聚类 bootstrap 下各组最佳时点的不确定性 (B=200)

分组	时点均值 (周)	标准差	95% 置信区间
G1 (BMI < 28)	9.98	1.249	[7.4, 12.1]
G2 (28 ~ 32)	11.93	0.795	[10.3, 13.5]
G3 (32 ~ 36)	13.88	0.770	[12.5, 15.4]
G4 (BMI $\geq$ 36)	15.84	1.201	[13.4, 18.1]




图 10: 检测误差下各组最佳时点的分布 (聚类 bootstrap B=200)

6 问题三：多因素综合的时点选择

6.1 多因素变量选择

在问题二的基础上引入年龄、身高、体重等多因素。由于体重与 BMI 高度相关 ($r = 0.835$)，二者不宜同时进入模型。以 AIC 准则进行变量选择，结果见表 9。模型 M3 (加入年龄与身高) AIC 最小 (706.9)，而再加入体重的 M4 AIC 反而上升 (707.5)，证实体重与 BMI 共线。故最优模型为

$$\ln Y_{ij} = \beta_0 + \beta_1 t_c + \beta_2 \text{BMI}_c + \beta_3 \text{age}_c + \beta_4 \text{height}_c + u_i + \varepsilon_{ij}. \quad (3)$$

表 9: 多因素模型变量选择 (AIC/BIC)

模型	变量	AIC	BIC
M1	week+BMI	710.0	734.9
M2	+age	709.0	738.9
M3	+age+height	706.9	741.8
M4	+age+height+weight	707.5	747.4

模型 M3 的系数估计见表 10。身高系数显著 ($p = 0.043$)，年龄系数边缘显著 ($p = 0.118$)，二者均为负，即高个子、高龄孕妇的胎儿 DNA 浓度略低。BMI 仍为主导因素。

表 10: 多因素模型系数 (REML 估计)

变量	系数	标准误	p 值
截距	-2.652	0.026	< 0.001
孕周	0.0435	0.002	< 0.001
BMI	-0.0196	0.007	0.008
年龄	-0.0111	0.007	0.118
身高	-0.0102	0.005	0.043

6.2 达标比例与最佳时点

以各组的中位 BMI、年龄、身高作为代表孕妇，计算达标比例与最佳时点，结果见表 11。与问题二（仅 BMI）相比，多因素修正幅度在 $-0.54 \sim +0.50$ 周之间，说明 BMI 仍是决定达标时点的主导因素，年龄与身高只起微调作用。

表 11: 问题二与问题三最佳时点对比 (单位：周)

分组	BMI 中位	仅 BMI (问题二)	多因素 (问题三)	差异
G1	27.6	10.82	10.59	-0.23
G2	30.4	12.11	11.57	-0.54
G3	33.5	13.59	13.23	-0.35
G4	37.3	15.39	15.89	+0.50

图 11 展示了多因素模型下各组的达标比例曲线，图 12 直观对比了问题二与问题三的最佳时点，可见多因素修正仅在 ± 0.5 周以内，两组结果高度一致，进一步印证 BMI

的主导作用；年龄与身高对最佳时点的影响见图 13。




图 11：多因素模型下各 BMI 组的达标比例曲线（虚线为最佳时点）




图 12：问题二（仅 BMI）与问题三（多因素）最佳时点对比




图 13: 年龄与身高对最佳时点的影响（G3 组，敏感性分析）

6.3 测量误差敏感性

固定 G3 组（BMI 中位 33.5），将测量误差 σ_e 在 0.5 ~ 1.5 倍之间缩放，观察最佳时点的变化，结果见表 12。测量误差越大，为保证达标比例，最佳时点越向后推迟； σ_e 从 0.124 增至 0.372 时，时点从 12.23 周推迟到 14.70 周，推迟约 2.5 周。这提示控制测序质量、降低测量误差可显著提前检测时点，检测误差对时点分布的影响见图 14。

表 12: 测量误差 σ_e 对最佳时点的影响（G3 组）

σ_e 倍数	0.50	0.75	1.00	1.25	1.50
σ_e	0.124	0.186	0.248	0.310	0.372
最佳时点（周）	12.23	12.66	13.23	13.92	14.70




图 14: 多因素模型下检测误差对最佳时点的影响 (聚类 bootstrap B=200)

7 问题四：女胎异常判定

7.1 数据与特征

女胎检测数据共 605 条 (147 位孕妇)，其中正常 538 例、异常 67 例 (非整倍体占 11.1%)，类别不平衡。异常类型包括 T18 (33 例)、T13T18 (11 例)、T13 (10 例)、T21 (9 例) 等。特征包括 13/18/21 号染色体 Z 值、X 染色体 Z 值与浓度、各染色体 GC 含量、读段数及比对/重复/过滤比例、BMI、年龄、身高、体重、孕周共 26 维。

关键观察：异常样本的 Z 值并未显著偏离正常。如表 13 所示，T18 样本的 18 号 Z 值均值仅 1.03，远低于 3 的阈值；异常样本中 $|Z| > 3$ 的比例仅为 0 ~ 4.5%。这说明传统的 $|Z| > 3$ 阈值法难以复现 AB 列的判定，异常标签是由多因素共同作用的结果。图 15 直观对比了正常与异常样本的 Z 值分布。

表 13: 各异常类型的对应染色体 Z 值均值

异常类型	样本量	Z13	Z18	Z21
T13	10	-0.20	0.28	0.39
T18	33	0.49	1.03	-0.16
T21	9	0.02	0.44	0.27
T13T18	11	0.52	0.73	0.65




图 15: 正常与异常样本的 Z 值分布对比（异常样本 Z 值未显著偏离）

7.2 判定方法

构建三类模型进行对比：传统 Z 值阈值法 ($|Z| > 3$ 判异常) 作为基线，逻辑回归与随机森林、梯度提升作为综合多特征的机器学习方法。针对类别不平衡，逻辑回归采用平衡类权重，随机森林采用平衡类权重，并以分层 5 折交叉验证评估。特征工程包括 Z 值的绝对值、多染色体 Z 值联合、GC 偏离正常中值的程度、X 染色体浓度的绝对值等。

7.3 结果与评估

各模型性能见表 14 与图 16。Z 值阈值法敏感度仅 6.0%，几乎无法识别异常，说明单靠 Z 值阈值判定失效。逻辑回归 AUC 达 0.794，敏感度 0.669、特异度 0.812；随机森林 AUC 同为 0.794，特异度更高（0.963）但敏感度较低（0.327）。对于异常判定这一”漏诊代价高”的场景，逻辑回归在敏感度上更优，可作为推荐方法。

表 14: 各模型 5 折交叉验证性能

模型	AUC	F1	敏感度	精确率	特异度
Z 值阈值法	—	0.071	0.060	0.089	0.924
逻辑回归	0.794	0.416	0.669	0.304	0.812
随机森林	0.794	0.394	0.327	0.543	0.963
梯度提升	0.785	0.341	0.269	0.530	0.967




图 16: 女胎异常判定的 ROC 曲线

由于类别不平衡（异常仅占 11.1%），精确率-召回率（PR）曲线比 ROC 更能反映判定质量。图 17 显示逻辑回归的 PR 曲线整体优于随机森林与梯度提升，逻辑回归的平均精确率 AP 为 0.458，随机森林与梯度提升分别为 0.405 与 0.446。




图 17：女胎异常判定的精确率-召回率曲线（不平衡数据）

特征重要性（表 15 与图 18）显示，X 染色体浓度（ X_{conc} 及其绝对值）是最重要的判别特征，其次为各染色体的 GC 含量与 BMI。这与题目背景”女胎以 X 染色体浓度判断检测是否准确”完全一致，说明女胎异常判定首先依赖 X 染色体信息的可靠性，再结合 GC 含量等测序质量指标综合判断。

表 15：随机森林特征重要性（前 6 位）

特征	重要性	说明
X_{conc}	0.138	X 染色体浓度
$ X_{\text{conc}} $	0.096	X 浓度绝对偏离
GC13	0.065	13 号染色体 GC 含量
GC21	0.052	21 号染色体 GC 含量
GC18	0.051	18 号染色体 GC 含量
BMI	0.051	孕妇 BMI




图 18: 随机森林特征重要性排序 (前 12 位)

针对类别不平衡 (异常仅占 11.1%), 进一步对比了 SMOTE 过采样 (在训练折内对少数类合成样本至平衡) 与类别权重平衡两种处理方法, 结果见表 16。二者 AUC 与敏感度相当 (0.795 vs 0.794), 表明类别不平衡并非性能瓶颈; 敏感度约 0.67 的上限源于异常样本的 Z 值未显著偏离正常 (见图 15), 而非采样策略所致。鉴于类别权重平衡无需合成样本、可解释性更强, 本文沿用该方法。

表 16: 类别不平衡处理方法对比 (逻辑回归, 5 折交叉验证)

方法	AUC	敏感度	特异度
类别权重平衡	0.794	0.669	0.812
SMOTE 过采样	0.795	0.684	0.827

7.4 可解释的判定公式

尽管随机森林通过特征重要性揭示了 X 染色体浓度与 GC 含量的判别作用, 但黑箱模型不利于临床落地。为此, 本文进一步拟合标准化逻辑回归, 给出可直接使用的线性判定公式。对特征做 z-score 标准化 $X'_j = (X_j - \mu_j)/\sigma_j$ 后, 异常概率的对数几率为

$$\log \frac{P}{1-P} = -0.846 + \sum_j \beta_j X'_j, \quad (4)$$

各特征系数 (按 $|\beta_j|$ 降序) 见表 17, 其余 14 个特征系数绝对值均小于 0.18, 判别贡献有限。当 $P > 0.5$ 时判为异常, 需进一步行羊水穿刺确诊。

表 17: 标准化逻辑回归系数（前 12 位）

特征	系数 β_j	均值 μ_j	标准差 σ_j
21 号染色体 GC 含量	-2.634	0.4012	0.0050
13 号染色体 GC 含量	1.660	0.3791	0.0044
18 号染色体 GC 含量	1.101	0.3919	0.0042
X 染色体浓度	-0.587	-0.0069	0.0180
X 染色体浓度	0.469	0.0151	0.0119
年龄（岁）	-0.439	30.018	4.305
体重（kg）	-0.317	83.816	9.556
孕周（周）	0.273	18.346	4.366
比对比例	0.269	0.7958	0.0177
重复读段比例	-0.261	0.0304	0.0034
21 号染色体 Z 值	0.256	-0.117	1.124
18 号染色体 Z 值	0.188	0.804	1.283

由表 17 可见，三号染色体的 GC 含量标准化系数最大，这是因为 GC 含量的原始量纲极小（标准差约 0.005），单位标准化变化即对应较大的几率偏移；X 染色体浓度系数为 -0.587，表明 X 浓度越低异常风险越高，与随机森林”X 染色体浓度是最重要判别特征”的结论一致，也印证了题目”女胎以 X 染色体浓度判断检测可靠性”的临床经验。

8 模型评价与改进

8.1 模型优点

混合效应模型正确处理了纵向重复测量结构，避免了横截面回归对孕周效应的低估，这是本文方法上的核心改进。达标时间采用”真实达标”与”测得达标”的区分，将检测误差的影响显式量化。女胎判定综合多特征后 AUC 由阈值法的接近 0.5 提升至 0.79，并识别出 X 染色体浓度的主导作用。

8.2 模型局限与改进

其一，达标时间的线性外推在数据范围（10-29 周）外不可靠，本文仅在检测窗口内使用，未外推到 10 周以前。其二，女胎分类的 AUC 为 0.79，仍有 33% 的异常样本被逻辑回归漏判。43 位孕妇的多次检测标签不一致引入了标签噪声，本文已测试孕妇级别的多数投票聚合，但 AUC 反而由 0.794 降至 0.733，原因是样本量由 605 条缩至 147

条、且聚合放大了个别误报，故保留检测级别建模。其三，风险权衡通过置信水平 α 体现，本文已对 α 在 60% ~ 95% 间扫描（见表 6）验证了 80% 选择的稳健性，但延误风险的三级离散设定（低/高/极高）仍可细化为连续函数；孕周二次项在决策窗口外推不可靠（见表 4），说明线性近似存在局限，未来可引入分段线性或样条模型。

9 参考文献

- [1] Lo Y M D, Corbetta N, Chamberlain P F, et al. Presence of fetal DNA in maternal plasma and serum[J]. The Lancet, 1997, 350(9076): 485-487.
- [2] Pinheiro J C, Bates D M. Mixed-Effects Models in S and S-PLUS[M]. New York: Springer, 2000.
- [3] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [4] Hosmer D W, Lemeshow S. Applied Logistic Regression[M]. 2nd ed. New York: John Wiley & Sons, 2000.

附录：代码与结果文件说明

本文全部计算由 Python 实现，依赖 `numpy`、`pandas`、`statsmodels`、`scikit-learn`、`matplotlib`。代码文件分别为 `problem1.py` 至 `problem4.py`，共享数据预处理模块 `data_utils.py`。所有图表输出于 `output/figures/`，关键结果表输出于 `output/` 目录下的 CSV 文件。